SOUTENANCE · GROUPE 6

SIDEFLIX

Quels films indépendants mettre en avant cette semaine ?

Matis Douay · Jérémy Caillaud · Rayan Faher Bonne

Data Engineering & Cloud Infrastructure · Albert School · 6 novembre 2026

Sideflix, le cinéma indépendant en streaming

ENTREPRISE FICTIVE · CHIFFRES HYPOTHÉTIQUES · RÉFÉRENCE : NETFLIX

10 000	7,99 €	≈ 80 k€	100	6
abonnés cinéphiles	par mois, sans pub	de CA par mois	titres au catalogue	employés

Problème

100 titres se disputent la mise en avant, chaque semaine

Contraintes

Chiffres prêts avant 07:00

Budget Snowflake : 10 crédits/mois

Parties prenantes

Abonnés, direction, responsable catalogue, producteurs indépendants

Un utilisateur, une décision par semaine

L'UTILISATEUR

Responsable catalogue

« Quels titres mettre en avant cette semaine ? »

- **06:00** · run quotidien (Paris)
- **Avant 07:00** · chiffres prêts
- **Chaque semaine** · décision

Métriques

Sessions valides
= session_id distincts

Minutes regardées
= somme des secondes vues ÷ 60 par titre et par jour (UTC)

Classement

Sur 7 jours :
minutes, puis sessions

Exclusions

Quarantaine avec motif
ID manquant, titre inconnu, date ou durée invalide

Doublons retirés

Test d'acceptation

1er nov. 2026

13 sessions

177,4 minutes

= calcul indépendant

Cinq sources réelles décrivent les films

IMDb
Identité et durée

FICHIER

Wikidata
Lien Wikipédia

API

Wikimedia
Popularité actuelle

API

MovieLens
Qualité perçue

FICHIER

Netflix Top 10
Succès réel

FICHIER

DONNÉES INTERNES DE SIDEFLIX

Catalogue
PostgreSQL local, 6 films

Sessions de visionnage
SIMULÉES

32 session · 6 films · 30 Oct – 1 Nov 2026

Visionnages simulés, contexte réel

Sessions simulées

- 1 session = 1 visionnage
- 32 lignes, 6 films, 3 jours

Silver : validation

- IMDb valide chaque session
- 30 valides, 1 en quarantaine, 1 doublon

Gold : classement

- Classé selon le visionnage
- Contexte réel affiché à part

LE 1er NOVEMBRE 2026

14 lignes brutes

− **1** en quarantaine

= **13** sessions valides

→ **177,4** minutes regardées

Trois types de sources, trois ingestions

Catalogue PostgreSQL

watermark + MERGE

BESOIN
Charger les lignes modifiées

ÉCARTÉ
Rechargement complet, CDC

Fichiers datés

stage + COPY INTO

BESOIN
Charger chaque lot une fois

ÉCARTÉ
Snowpipe (fichiers en continu)

API publiques

JSON → VARIANT

BESOIN
Garder le JSON brut, rejouable

ÉCARTÉ
Aplatir le JSON en Python

En Bronze : valeurs brutes, heure de chargement, ID de lot.

Erreurs bloquées tôt, rejeux sans doublon

1 check_sources

Sources complètes pour la date ?

→

2 Silver

Quarantaine et dédoublonnage

→

3 Tests dbt

Fraîcheur + 21 tests : clés, règles, Gold = Silver

→

4 Publication

MERGE sur la date

Un seul test en échec, et rien n'est publié.

RÉCONCILIATION

32 = 30 + 1 + 1

lignes brutes = valides + quarantaine + doublon

BILAN DBT

33 / 33

opérations vertes : 11 modèles, 21 tests, 1 hook d'audit

TEST DE REJEU

0

ligne ajoutée au rejeu de la date

Des outils à la mesure d'un batch quotidien

Snowflake

AWS Paris (eu-west-3)
X-Small, pause après 60 s

plutôt que BigQuery

dbt

SQL versionné, 21 tests, documentation et lineage

plutôt que des procédures stockées

Pas de streaming

Une décision par semaine : un run par jour, ≈ 1 min.

Airflow + Docker

En local, planifié à 06:00 (Paris), 2 relances, alerte Slack

plutôt que Snowflake Tasks

Terraform

Warehouse déclaré en code, state verrouillé

GCS plutôt que S3 (écart assumé)

PREUVE · RÉGION

```
SELECT
CURRENT_REGION();
```

AWS_EU_WEST_3

≈ 1,5 crédit par mois, plafonné à 10

1,44

crédit mesuré

du 3 au 4 nov. : développement, tests et incidents

≈ 1,5

crédit par mois, projeté

30 runs × 131 s × 1,35 crédit/h

10

crédits par mois, plafond

monitor : alerte à 50 % et 80 %, suspension à 100 %

Moindre privilège

Pipeline sans DELETE en Bronze

Analyste : lecture de Gold

11 tests : 3 autorisés, 8 refusés

Secrets et données

Clés, .env et webhook hors de Git

Aucun viewer_id dans Gold

Arrêt documenté

DAG en pause, compose down, warehouse suspendu

Nettoyage après la notation

L’architecture exécutée, de bout en bout

SOURCES → INGESTION · JOBS PYTHON DANS DOCKER, EN LOCAL

Fichiers
IMDb, MovieLens, Netflix, sessions

PostgreSQL
catalogue des 6 films, en local

API publiques
Wikidata, Wikimedia, en direct

stage + COPY INTO

watermark + MERGE

JSON → VARIANT

SNOWFLAKE · AWS PARIS (eu-west-3)

BRONZE
données brutes, ID de lot

SILVER · dbt
typage, doublons, quarantaine

GOLD · dbt
usage quotidien, classement 7 jours

PUBLICATION
MERGE, 1 ligne par date Snowsight lit Gold

Airflow + Docker
06:00 Paris, 2 relances, Slack

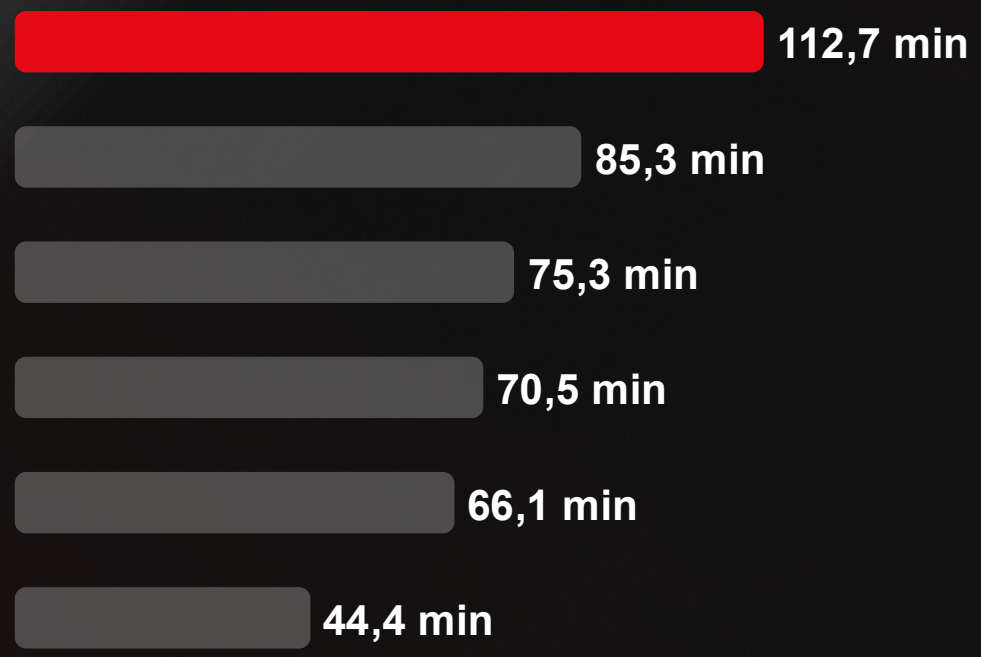
Terraform
warehouse en code, state GCS

Contrôles
tests, rôles, plafond 10 crédits

Whiplash en tête du classement sur 7 jours

Quels titres mettre en avant cette semaine ?

Source : GOLD_EDITORIAL_WEEKLY · fenêtre UTC 26 oct. – 1er nov. 2026
Fraîcheur : Gold construit le 4 nov. 2026 à 19:48 UTC



CONTEXTE RÉEL

affiché à côté, jamais mélangé

Whiplash
MovieLens : 4,04 (38 notes)

Sicario
5e du Top 10 Netflix
films en anglais, 3–9 mars 2025

VISIONNAGES SIMULÉS

30 sessions · 454,2 min

cumul sur 3 jours de données

Run en direct : une date, une ligne



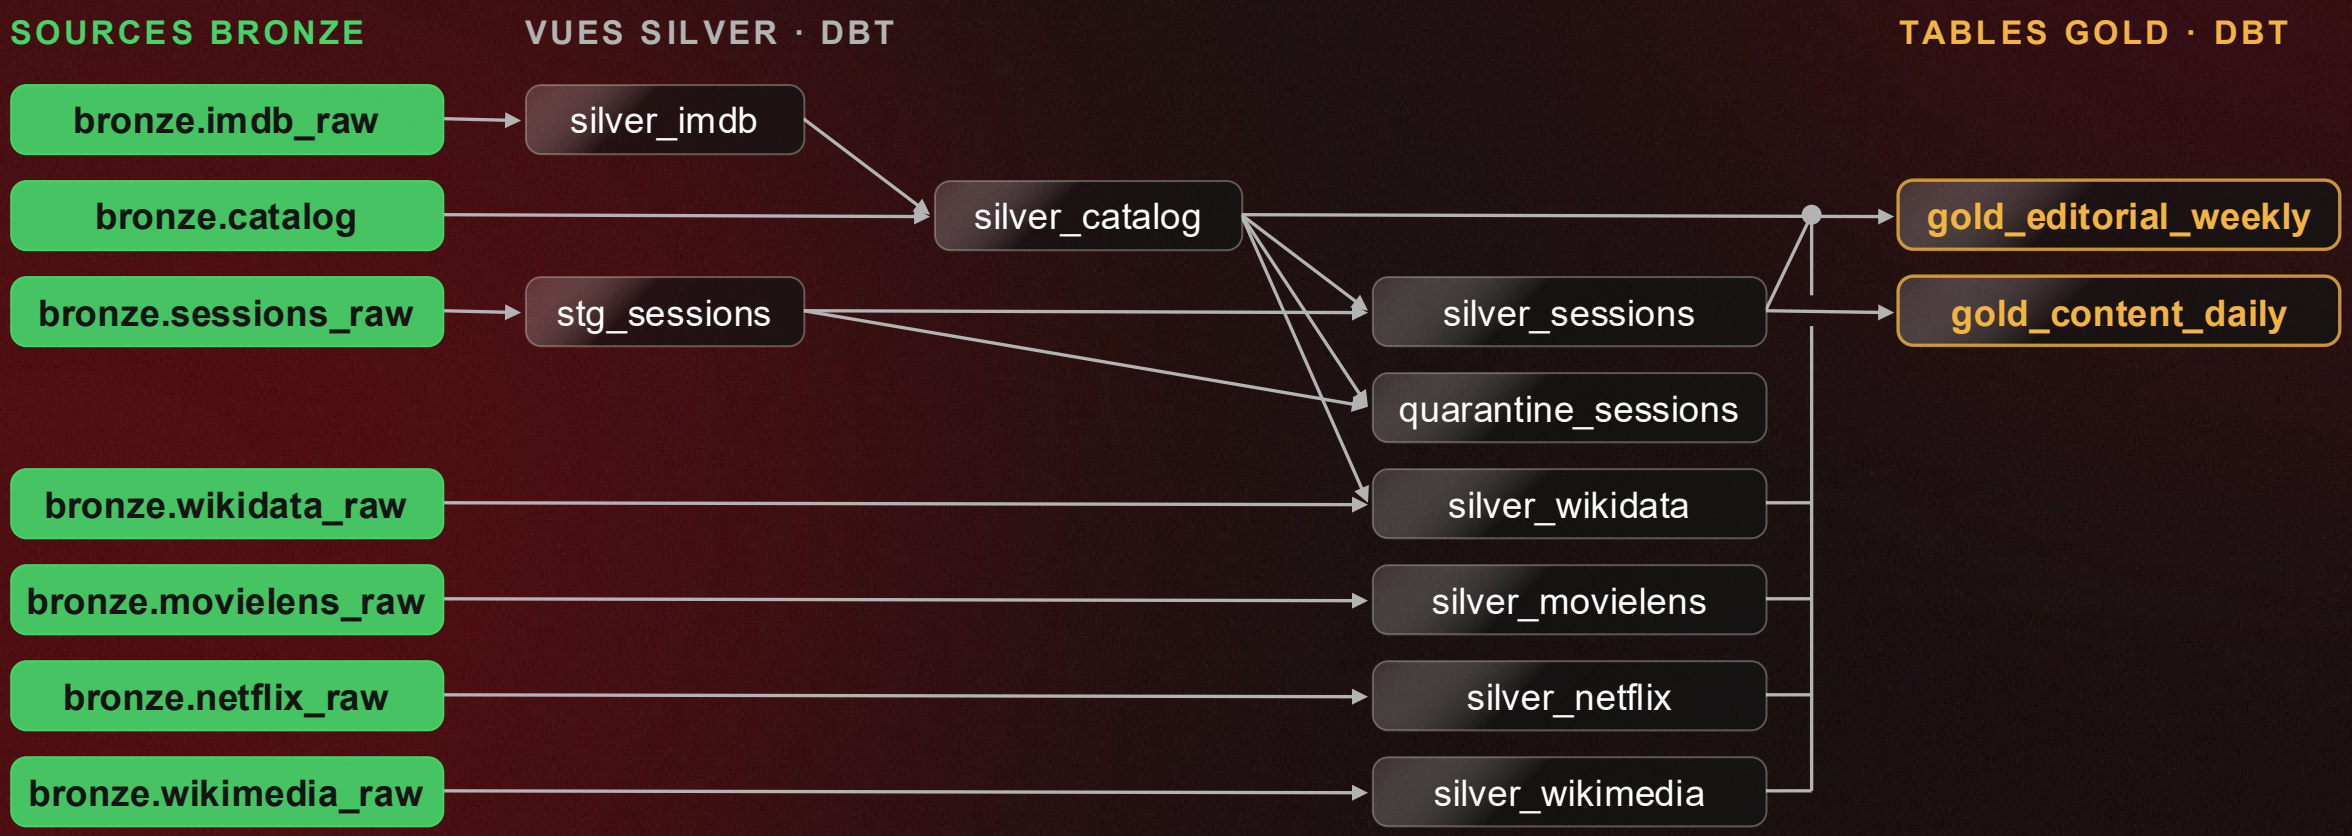
EN DIRECT

Répété le 5 nov.
avec le code livré

0 erreur

0	**Avant**	run planifié sans données : échec, alerte Slack
1	**Déclencher**	{"date":"2026-11-01"}
2	**Rôle analyste**	**lire Gold ✓** · **lire Bronze ✗** · **écrire ✗**
3	**Airflow**	4 tâches vertes · dbt 33/33 · une publication
4	**Snowsight**	1 ligne : 13 sessions · 177,4 min
5	**Lineage**	docs/dbt/index.html, de Bronze à Gold

Chaque chiffre Gold remonte à Bronze



21 tests 15 génériques sur Silver · 6 singuliers, dont Gold = Silver et 32 = 30 + 1 + 1

Deux incidents injectés, reprises propres

EN DIRECT

Crash après l'écriture

- MERGE publié, puis crash simulé
- Airflow relance seul après 20 s
- 2e tentative : publication réussie
- Toujours 1 ligne : 13 sessions, 177,4 min

MERGE sur la date : jamais de double comptage.

SI LE TEMPS LE PERMET

Donnée invalide

- Appareil « invalid » injecté
- Le test accepted_values échoue
- Publication bloquée, alerte Slack
- Nettoyage ciblé, puis run vert

Gold et la publication restent intacts.

Slack · une alerte part dès qu'une tâche échoue après sa dernière relance

Nos limites, et qui a fait quoi

Limites assumées

- Entreprise fictive, Netflix comme référence
- Visionnages simulés, et signalés comme tels
- Sources réelles sur des périodes différentes
- Top 10 Netflix : seul Sicario confirmé
- Airflow et PostgreSQL tournent en local
- GCS ne sert qu'au state Terraform
- Incidents injectés exprès, mais réels

Matis Douay — SOURCES & DONNÉES

Sources, ingestion, dbt Silver et Gold, incidents, vidéo, captures Snowsight

Jérémy Caillaud — PLATEFORME & OPÉRATIONS

Snowflake, Terraform, runs Docker/Airflow, alertes Slack, rôles, coûts, premières diapos

Rayan Faher Bonne — RESTITUTION

Restitution Gold : reporting Snowsight

Merci

Des questions ?

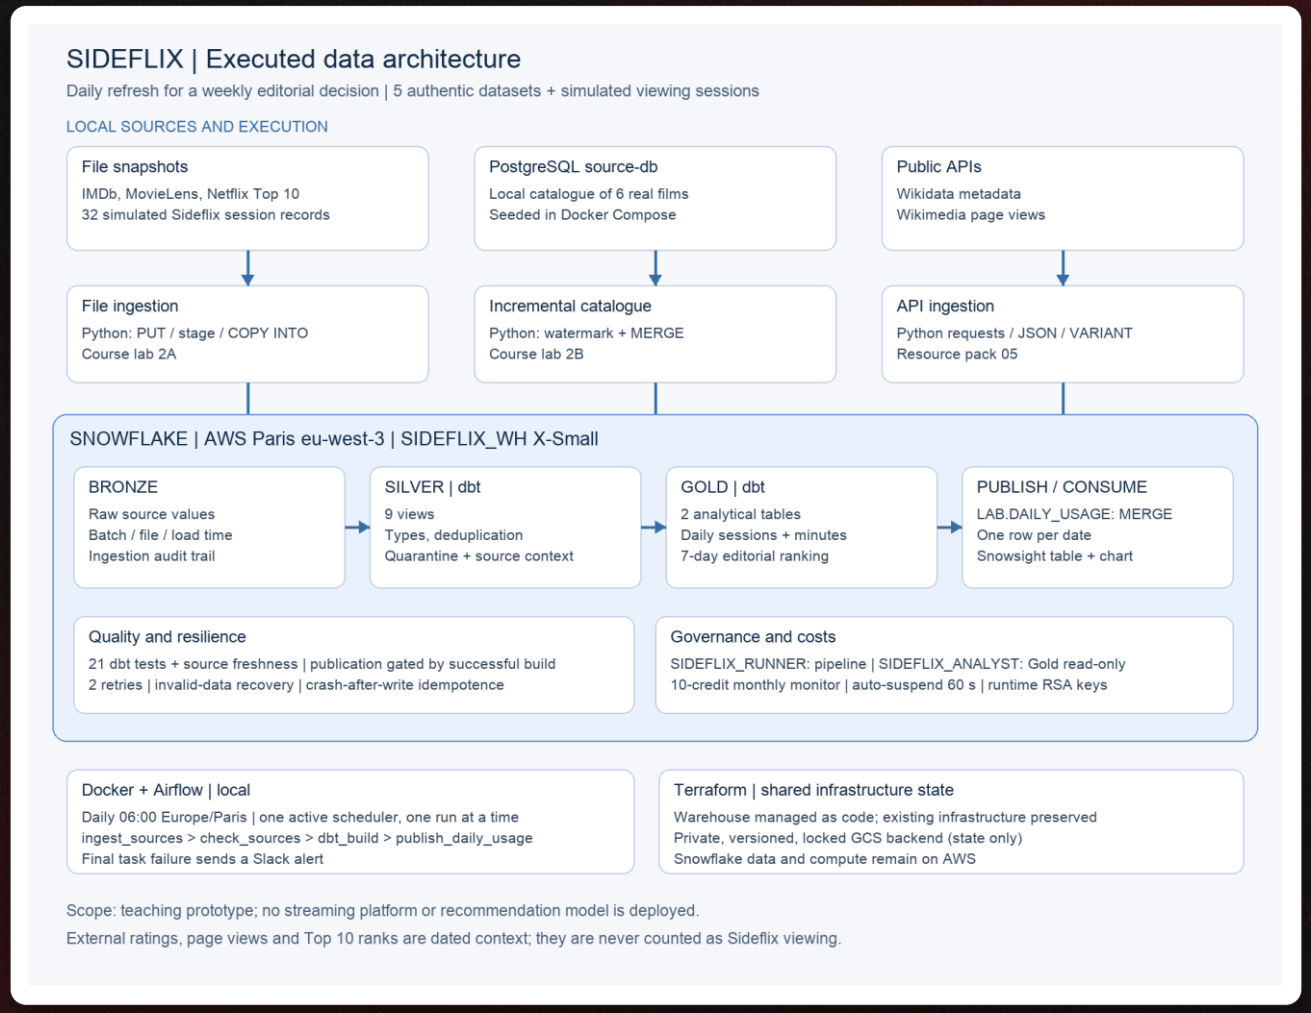
13 · 177,4	33 / 33	2	≈ 1,5
sessions · minutes le 1er nov., une seule ligne	opérations dbt vertes	incidents injectés, deux reprises	crédit par mois, plafond à 10

Dépôt : github.com/CLDprog/SideFlix-Project

Matis Douay · Jérémy Caillaud · Rayan Faher Bonne · Groupe 6

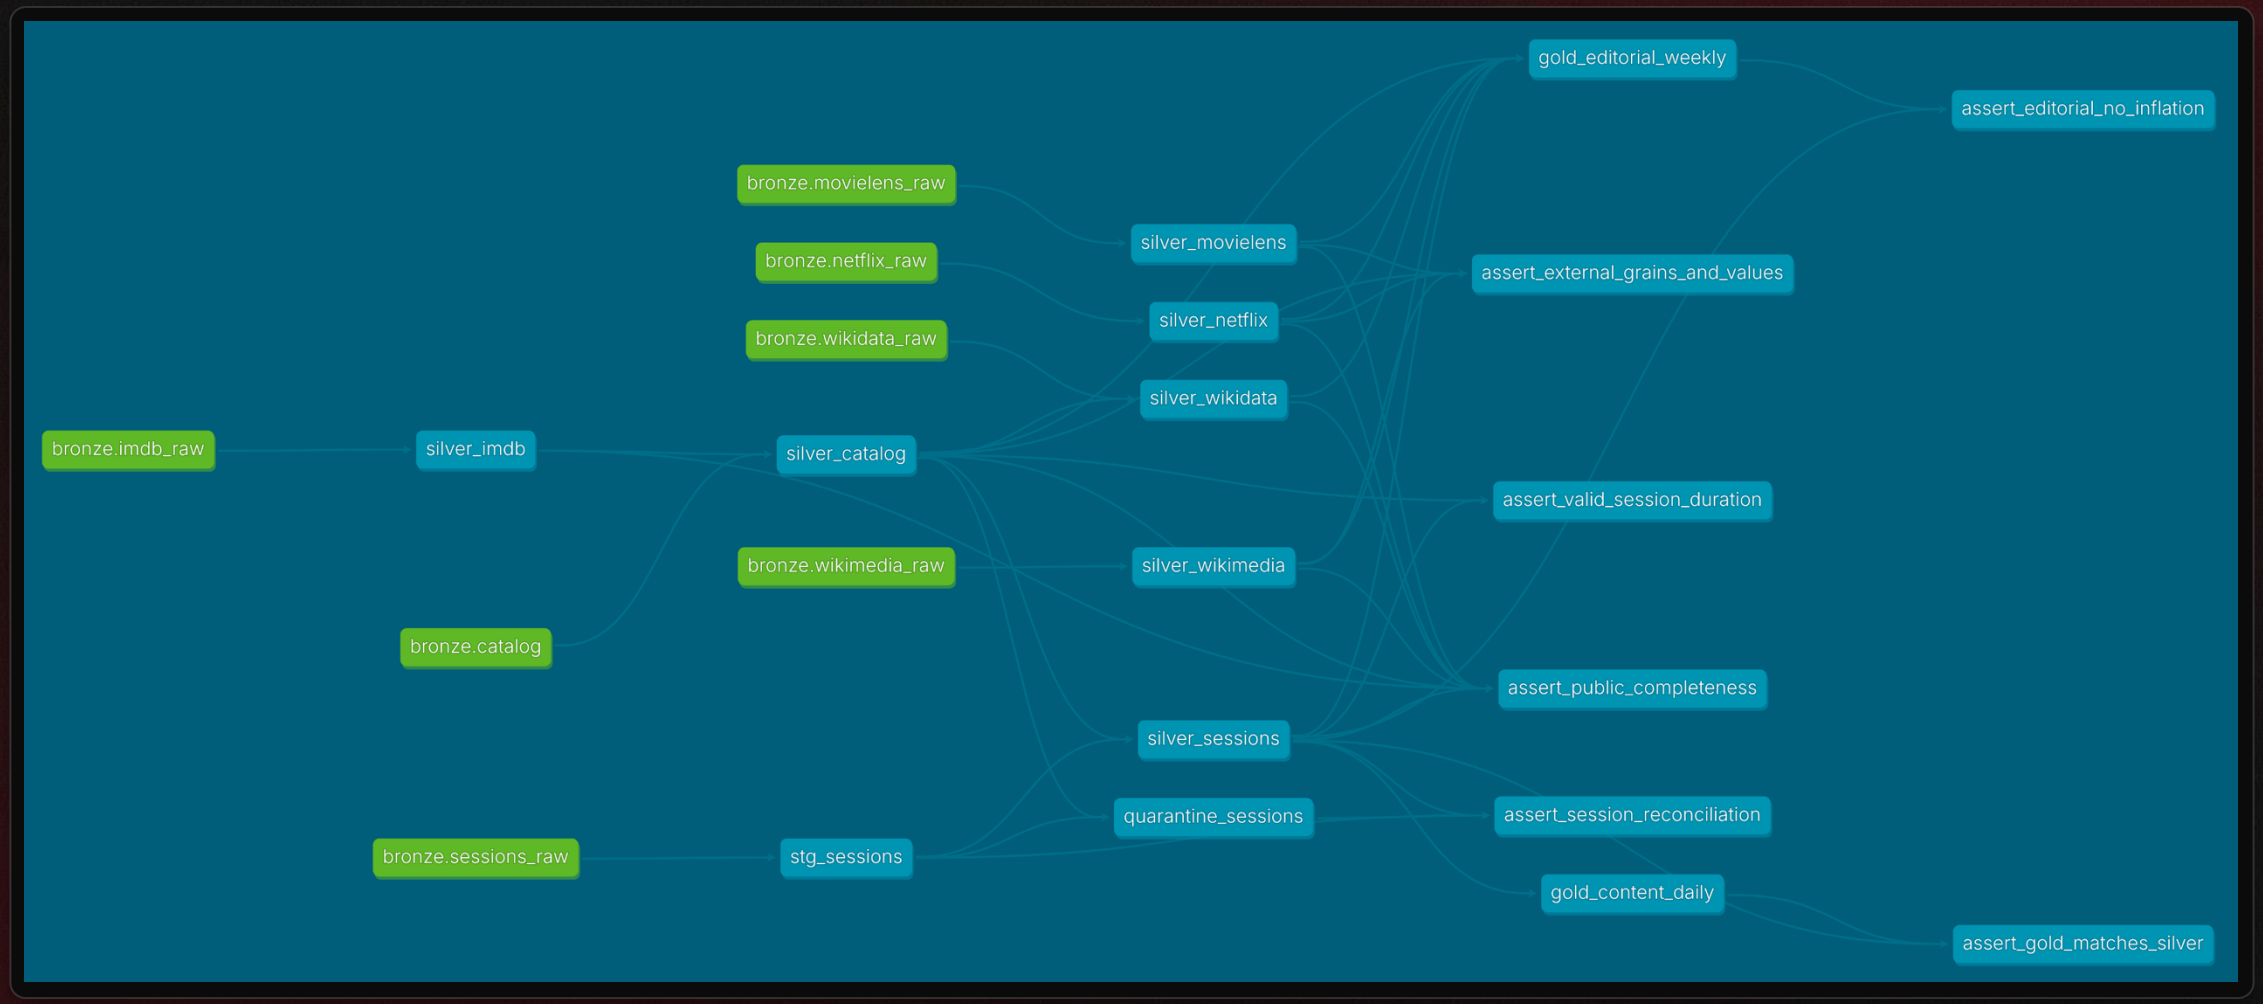
ANNEXE

Schéma d’architecture, tel que livré



ANNEXE

Lineage dbt, tel que généré



ANNEXE

Graphique Snowsight, tel que capturé

